Sistemas de Aprendizaje Automático

Conforme a contenidos del «Curso de Especialización en Inteligencia Artificial y Big Data»



Sistemas de
Aprendizaje_Automático

Universidad de Castilla-La Mancha

Escuela Superior de Informática
Ciudad Real

Caracterización de sistemas de aprendizaje automático

1.3. Construcción de modelos de aprendizaje automático

1.3.1. ¿Que es un modelo?

Los métodos de aprendizaje automático son ejemplos notables de la llamada IA débil. En los métodos de aprendizaje automático el dominio de aplicación está delimitado y es conocido. Estos métodos elaboran un **modelo matemático** de esta realidad. Según Marvin Lee Minsky, M es un modelo (matemático) de una realidad R para un observador O si se cumple las siguientes dos condiciones:

i) El modelo M contesta a las preguntas que el observador O hace sobre la realidad R

ii) Los datos que genera el modelo M sobre la realidad R reproducen las observaciones que se dispone del fenómeno R.

La condición i) apunta a que tipo de datos deben registrarse y ser usados. Estos deben estar alineados con los objetivos del estudio. La condición ii) afirma que los modelos no intentan *sintetizar la verdad* sino simplemente reproducir las observaciones. Por ejemplo, la física Newtoniana será un modelo válido para un observador O de la vida cotidiana pero no para un observador O' que analice problemas de astrofísica, ya que esta teoría no es capaz de reproducir las observaciones relativas a la distorsión del espacio y tiempo en torno a un cuerpo gravitacional. En este caso hay que elaborar nuevos modelos como la teoría de la relatividad de Einstein.

La Figura 1.2 esquematiza el concepto de modelo. El aprendizaje automático considera *la realidad* (dominio de aplicación) como una *caja negra* que para una entrada $\mathbf{x}$ genera una salida $\mathbf{y}$. El modelo de aprendizaje automático simula este proceso sin reproducir los mecanismos causales que operan en la realidad. El modelo busca exclusivamente que las predicción del modelo (denotada $\hat{\mathbf{y}}$) y las observaciones sean coincidentes.

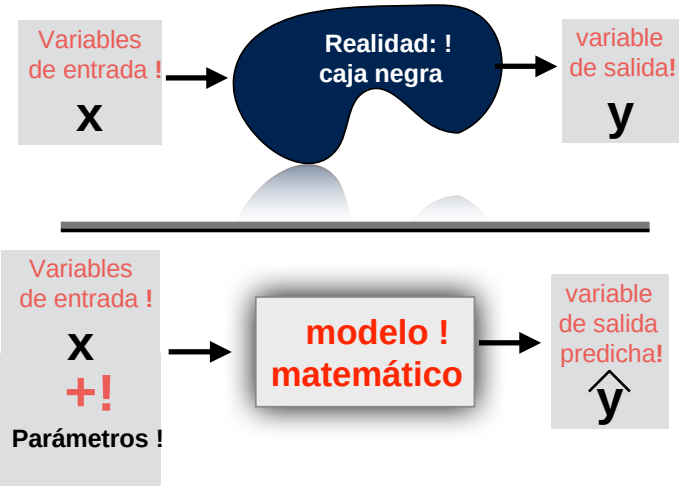


Figura 1.2: Modelización matemática.

De forma sintética un modelo matemático se puede expresar:

$$\mathbf{y} = F_{\boldsymbol{\theta}}(\mathbf{x}, \boldsymbol{\alpha}) \tag{1.1}$$

donde $\mathbf{y}$ es la respuesta del sistema (variable respuesta) que puede ser un número, un vector, una matriz, etc., y $\mathbf{x}$ son los datos de entrada que a su vez puede ser un número, un vector, una matriz, etc. El símbolo $\boldsymbol{\alpha}$ representa un vector de **parámetros** (en el contexto de las redes neuronales se les llaman los pesos). La familia de funciones (modelos) $F_{\boldsymbol{\theta}}$ está parametrizada por un conjunto diferente de parámetros $\boldsymbol{\theta}$ que reciben el nombre de **hiperparámetros**. Esto permite ensayar más de un solo modelo, mejorando el resultado final.

El problema de **entremaniento** (ajuste) del modelo consiste en encontrar, para un valor dado de los hiperparámetros $\boldsymbol{\theta}$, el vector de parámetros $\boldsymbol{\alpha}$ que mejor describa las observaciones existentes.

Ejemplo. Un modelo para relacionar dos variables $\mathbf{x}$ e $\mathbf{y}$ puede ser una función polinomial. En este caso se tiene la siguiente expresión de la variable respuesta en función de la variable de entrada, parámetros e hiperparámetro:

$$\mathbf{y} = F_{\boldsymbol{\theta}}(\mathbf{x}, \boldsymbol{\alpha}) = \alpha_0 + \alpha_1 x + \alpha_2 x^2 + \ldots + \alpha_\theta x^\theta \tag{1.2}$$

En este ejemplo el grado del polinomio θ es el hiperparámetro del modelo. Este parámetro permite considerar una variedad amplia de modelos. Por ejemplo, si tomamos $\theta = 1$ estamos considerando una recta, si elegimos $\theta = 2$ estaríamos analizando parábolas. Fijado el valor de θ se trata de encontrar los coeficientes del polinomio (problema de entrenamiento) que mejor describan los datos. La Figura 1.3 muestra dos ejemplos. Supóngase que tenemos tres datos (cuadrados rojos), si nos planteamos un modelo lineal $F_{\boldsymbol{\theta}}(\mathbf{x}, \boldsymbol{\alpha}) = \alpha_0 + \alpha_1 \mathbf{x}$ para describir los datos (gráfica de la derecha) tendríamos que ajustar dos parámetros (α_0, α_1) para encontrar la recta *más cercana a los puntos*. Si decidimos buscar una parábola tendríamos un modelo con tres parámetros $F_{\boldsymbol{\theta}}(\mathbf{x}, \boldsymbol{\alpha}) = \alpha_0 + \alpha_1 \mathbf{x} + \alpha_2 \mathbf{x}^2$. Si ajustamos los tres parámetros adecuadamente podemos encontrar una parábola que pase por los tres puntos. Cuando buscamos un modelo que reproduzca exactamente las observaciones se denomina un problema de interpolación mientras que si lo que se desea es que se describa aproximadamente el conjunto de observaciones se denomina un problema de aproximación.

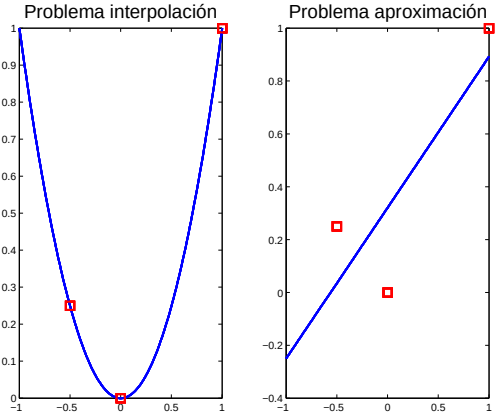


Figura 1.3: Modelo cuadrático y lineal.

1.3.2. Principales técnicas para desarrollar modelos de aprendizaje automático

El aprendizaje automático incluye un conjunto de técnicas que permiten que los ordenadores aprendan a realizar unas tareas determinadas. Algunas de estas técnicas se basan en un **aprendizaje deductivo**, que parte de reglas generales para obtener conclusiones particulares. En estos casos se especifican mecanismos causales en la construcción del modelo $F_{\boldsymbol{\theta}}$. Un ejemplo de estas técnicas es el razonamiento basado en casos que es usado en los **sistemas expertos**. Los sistemas expertos es un modelo de inteligencia artificial que intenta imitar el comportamiento de un ser humano experto en alguna temática.

Otras técnicas, como árboles de decisión o redes neuronales artificiales, emplean un **aprendizaje inductivo**, ya que a partir de la observación y el análisis de ejemplos concretos se desarrollan modelos que explican dichos datos y que permiten llevar a cabo una generalización. En estos casos los modelos F_{θ} actúan como *cajas negras*. En este módulo vamos a estudiar exclusivamente este último tipo de modelos.

1.4. Clasificación de sistemas de aprendizaje automático

La clasificación de los problemas de aprendizaje automátio se basan en dos criterios: i) la posibilidad o no de conocer la variable respuesta $\boldsymbol{y}$ y ii) la tipología de la variable respuesta $\boldsymbol{y}$. Por este motivo comenzaremos estableciendo los tipos de variables que se pueden considerar en un problema.

1.4.1. Tipología de las variables

Una clasificación de las variables en función de su naturaleza es:

- **Variables cuantitativas.** Los datos toman valores numéricos. A su vez se distingue entre **variables continuas** que toman valores en un intervalo de números reales o **variables discretas**, que toman un número finito de valores numéricos. Ejemplos de variables continuas son la edad, ingresos, altura, etc y como variables discretas el número de hijos, o el número de días realizando un tratamiento.

- **Variables ordinales.** Los datos expresan relación de orden entre las observaciones. Por ejemplo podemos considerar un *ranking* en ciertos tratamientos como el mejor (1), el segundo mejor (2), el tercer mejor (3), etc. Otro ejemplo son las variables que ordenan las preferencias de ciertos usuarios.

- **Variables cualitativas.** En este caso se expresa una cualidad de un objeto. Estas variables solo pueden tomar un conjunto de valores que no miden ninguna magnitud determinada. Por ejemplo, los sujetos de un experimento pueden ser hombre o mujer. Estos datos los podemos codificar dándole el valor 1 a los hombres y 2 a las mujeres. Esta variable no representa que el valor 2 es el doble del valor 1 (si fueran datos cuantitativos) o que unos son los segundos y los otros los primeros (datos ordinales) sino que son dos categorías diferentes. Este es un ejemplo de **variables binarias** en las que solo se pueden tomar dos valores.

1.4.2. Aprendizaje supervisado y no supervisado

Existe una gran cantidad de algoritmos de aprendizaje automático y corremos el riesgo de perdernos en un mar de siglas que inicialmente no aportan más que confusión. Es por esto necesario crear un mapa mental para organizarlos, en función del tipo de aprendizaje que utilizan y del tipo de problema que abordan.

Esta taxonomía de los algoritmos de aprendizaje automático se basa en la naturaleza de las variables del problema. Supongamos que tenemos un modelo como el de la ecuación (1.2) y denotamos por $\mathbf{x}$ e $\mathbf{y}$ respectivamente la variable de entrada y de salida, cada una puede ser de cualquier tipo de los anteriormenete presentados (cuantitativa, ordinal o cualitativa).

El modelador siempre dispone de un conjunto de observaciones $\{\mathbf{x}_i\}_{i=1}^N$ donde $\mathbf{x}_i$ es la variable de entrada de la observación i mientras que no siempre se dispone de las etiquetas $\mathbf{y}_i$ asociada a la observación i.

El **aprendizaje supervisado** supone que partimos de un conjunto de datos etiquetado previamente, es decir, conocemos $\{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^N$ para el conjunto de datos que disponemos. El aprendizaje **no supervisado** parte de datos no etiquetados previamente, esto es, exclusivamente dispone de la información $\{\mathbf{x}_i\}_{i=1}^N$. Dentro de estas dos situaciones aparecen tres tipos de problemas (ver la Figura 1.4):

- **Clustering**. En este problema se busca patrones dentro de los datos. Esto es, encontrar subconjuntos de observaciones que son similares entre sí. Matemáticamente se formularía como determinar las etiquetas $\mathbf{y}$ de los datos de modo que si dos observaciones i y j son similares le asociemos la misma etiqueta, $y_i = y_j$. Una dificultad de este problema es que no se parte de un conjunto previo de etiquetas del cual aprender. Un ejemplo de este tipo de problemas es la segmentación de mercados. Si se realiza un análisis *cluster* sobre los clientes de una determinada empresa se puede encontrar patrones de clientes y con ellos ofrecer productos especialmente diseñadas para estos segmentos.

- **Regresión**. En este problema se predice el valor de una variable continua $\mathbf{y}$ conocida el valor de la variable $\mathbf{x}$. En este problema la variable $\mathbf{x}$ se suele denominar **regresor** o **variable explicativa** mientras que $\mathbf{y}$ se denomina **variable respuesta** o **variable dependiente**. Un ejemplo de este tipo de problema aparece en los sistemas de recomendación que emplean plataformas de streaming como Spotify, YouTube y Netflix. Estos sistemas estiman funciones de regresión $y = f(\mathbf{x}_1, \mathbf{x}_2)$ que permiten estimar el tiempo de consumo de un usuario (y) para un usuario que ha consumido el producto 1 con características $\mathbf{x}_1$ e inicia el consumo del segundo producto con características $\mathbf{x}_2$.

- **Clasificación**. En este problema se debe predecir el valor de la variable cualitativa $\mathbf{y}$ a partir de la variable $\mathbf{x}$. En clasificación la variable $\mathbf{x}$ se denomina **características** o **atributos** mientras que $\mathbf{y}$ se denomina **etiqueta**. El coche autónomo se basa en tres pilares: IoT, técnicas de aprendizaje automático

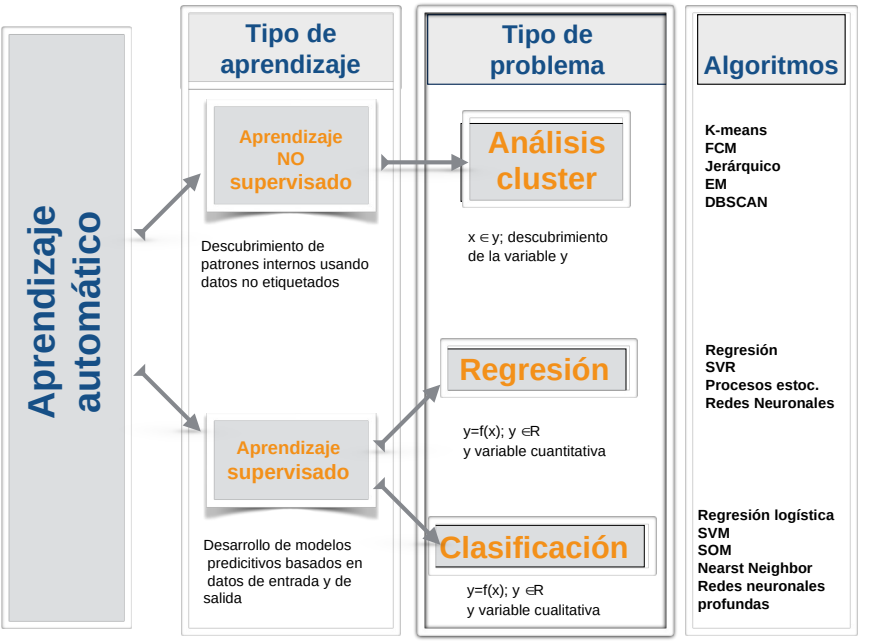


Figura 1.4: Aprendizaje supervisado y no supervisado.

aplicado a Big Data y conexión a internet a tiempo real. En la construcción de *los ojos* del vehículo se requiere resolver el problema de clasificar las imágenes que rodean al vehículo y poder así determinar que tipo de objeto está delante, detrás o a los lados del vehículo.

La figura 1.4 muestra la clasificación de los modelos de aprendizaje automático. Para cada tipo de problemas se han propuesto multitud de algoritmos. No existe un método que sea mejor que otro para todas las circunstancias por lo que es necesario disponer de una *caja de herramientas* con las que poder ensayar diferentes soluciones. A modo de ilustración de lo que queremos decir, el algoritmo *K-means* es rápido y funciona bien para problemas de *clustering* en los que los patrones se pueden separar linealmente (entre los grupos existentes se pueden intercalar hiperplanos que los separe). Este método constituye por tanto una buena alternativa en muchas aplicaciones pero si el problema no es linealmente separable el algoritmo *K-means* no sería capaz de identificar los patrones adecuadamente y por tanto habría que recurrir a técnicas alternativas como algoritmos basados en densidad (DBSCAN).